VISUALISASI DATA TIME-SERIES MENGGUNAKAN CONVOLUTIONAL NEURAL NETWORK PADA DATA CUACA BANDUNG 2022 - 2025(CNN)



Disusun Oleh

Ishak Palentino Napitupulu — 13524022;

Marcel Luther Sitorus — 13524063.

Sistem Cerdas TF4018

Institut Teknologi Bandung, 2026

.

ABSTRAK

Penelitian ini mengeksplorasi visualisasi representasi temporal meteorologi Bandung menggunakan convolutional autoencoder (CAE) 1D dan 2D. Dataset berisi 35.064 observasi per jam selama 2022–2025, dengan tujuh fitur numerik. CNN 1D mempelajari rekonstruksi window multivariat 48 jam; CNN 2D mempelajari rekonstruksi citra kemiripan rekuren temperatur berukuran 32×32. Pembagian kronologis adalah train 2022–2023, validation 2024, test 2025. Pada eksperimen awal tiga epoch, MSE test CNN 1D adalah 0,8924 pada ruang data terstandardisasi, sedangkan CNN 2D 0,0908 pada ruang citra kemiripan; nilai tersebut tidak dapat dibandingkan langsung. Aktivasi, kernel, rekonstruksi, dan embedding PCA berhasil divisualisasikan. Kontribusi penelitian berupa penyajian dan pembacaan visual input, rekonstruksi, aktivasi, kernel, serta embedding; penelitian tidak menargetkan penemuan pola meteorologi baru.

Kata kunci: time-series, meteorologi, convolutional autoencoder, recurrence similarity, interpretabilitas.

1. PENDAHULUAN

1.1 Latar Belakang

Visualisasi garis membantu mengamati tren meteorologi, tetapi kurang menonjolkan hubungan antarkondisi yang terpisah dalam waktu. CNN dapat mempelajari transformasi representasi dari window deret waktu; visualisasi aktivasi diperlukan agar fitur yang dipelajari tidak diperlakukan sebagai penjelasan kausal.

1.2 Rumusan Masalah

Informasi apa yang dapat diperoleh dari visualisasi input, feature maps, rekonstruksi, dan embedding CNN 1D? Bagaimana citra kemiripan rekuren dan aktivasi CNN 2D menyajikan hubungan antarwaktu? Bagaimana kedua pendekatan berbeda dari sisi keterbacaan dan kehilangan informasi?

1.3 Tujuan Penelitian

Menghasilkan dan menginterpretasikan visualisasi data time-series meteorologi menggunakan representasi CNN 1D dan CNN 2D; membandingkan bentuk dan keterbacaan visualisasi, sementara galat rekonstruksi hanya memeriksa keberlangsungan pembelajaran.

1.4 Batasan Penelitian

Observasi Bandung 2022–2025; tujuh fitur kontinu untuk 1D, hanya temperatur untuk 2D; window 48 jam; eksperimen awal tiga epoch pada CPU. Tidak ada forecasting, klaim sebab-akibat, atau generalisasi lintas lokasi.

1.5 Manfaat Penelitian

Memberikan contoh pipeline yang dapat direproduksi untuk melihat data meteorologi melalui grafik konvensional, respons filter temporal, citra kemiripan, dan representasi laten; tidak mensyaratkan penemuan fenomena baru.

2. TINJAUAN PUSTAKA

2.1 Data Time-Series

Data time-series adalah pengukuran berurutan dengan dependensi temporal; pola cuaca dapat memiliki siklus harian dan variasi musiman.

2.2 Visualisasi Data Time-Series

Line plot, moving average, distribusi, dan korelasi memberi konteks; matriks kemiripan rekuren menyoroti pasangan waktu dengan keadaan serupa.

2.3 Convolutional Neural Network (CNN)

Konvolusi 1D mempelajari pola lokal sepanjang waktu; konvolusi 2D mempelajari struktur lokal citra. Autoencoder meminimalkan galat rekonstruksi dan menghasilkan representasi internal, tetapi aktivasi tinggi tidak otomatis membuktikan makna meteorologis.

2.4 Penelitian Terdahulu

Eckmann, Kamphorst, dan Ruelle (1987) memperkenalkan recurrence plots. Wang dan Oates (2015) mengeksplorasi pengkodean deret waktu menjadi citra untuk klasifikasi. Fawaz dkk. (2019) mengulas deep learning untuk klasifikasi time-series; penelitian ini berbeda karena menitikberatkan visualisasi dan reconstruction learning.

3. METODOLOGI PENELITIAN

3.1 Alur Penelitian

Dataset → audit dan EDA → split kronologis → standardisasi train-only → window 48 jam → (a) CNN 1D atau (b) citra kemiripan rekuren + CNN 2D → reconstruction loss → visualisasi aktivasi, kernel, embedding

→ interpretasi.

3.2 Dataset dan Sumber Data

https://open-meteo.com/en/docs/historical-weather-apiDataset data/raw/BandungRawWeather.csv mengikuti format Open-Meteo Historical Weather API (https://open-meteo.com/en/docs/historical-weather-api); data hasil audit 35.064 jam, 2022–2025, Asia/Jakarta. Fitur: temperature_2m, relative_humidity_2m, dew_point_2m, precipitation, pressure_msl, cloud_cover, wind_speed_10m. Weather_code tidak diperlakukan sebagai besaran kontinu.

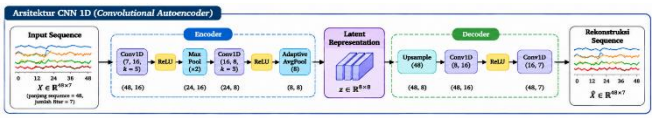
3.3 Eksplorasi dan Pemahaman Data

Pipeline tahap 1–5 memeriksa frekuensi, duplikasi, missing values, distribusi, korelasi, dan pola harian/bulanan. Audit tersimpan melaporkan tidak ada missing timestamp atau duplikasi; angka perlu diverifikasi ulang pada environment lain.

3.4 Preprocessing Data

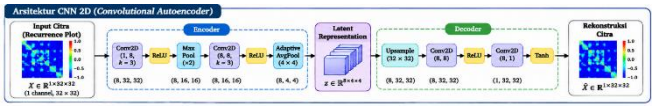
StandardScaler hanya difit pada 2022–2023; validation 2024 dan test 2025 ditransformasikan menggunakan parameter yang sama. Window 48 jam tanpa overlap dipilih untuk percobaan awal; jumlah window 365/183/182. Citra 2D dibentuk dari temperatur setiap window yang disampel ke 32 titik dan dinormalisasi min–max per-window: S(i,j)=exp(-|u_i-u_j|/0,25). Ini *continuous recurrence similarity*, bukan recurrence plot biner konvensional. Normalisasi per-window menghilangkan informasi level temperatur absolut.

3.5 Perancangan dan Penerapan CNN



Gambar 3.5.1. Arsitektur Convolutional Autoencoder CNN 1D.

Gambar 3.5.1 memperlihatkan arsitektur CNN 1D berbasis convolutional autoencoder yang digunakan untuk mempelajari representasi temporal dari data meteorologi multivariat. Model menerima masukan berupa sequence sepanjang 48 pengamatan dengan tujuh fitur meteorologi. Pada bagian encoder, dua lapisan konvolusi satu dimensi dengan jumlah filter masing-masing 16 dan 8 digunakan untuk mengekstraksi karakteristik temporal. Fungsi aktivasi ReLU memperkenalkan nonlinieritas, sedangkan MaxPooling dan Adaptive Average Pooling mereduksi dimensi temporal hingga menghasilkan representasi laten berukuran 8 × 8. Selanjutnya, bagian decoder menggunakan interpolasi melalui proses upsampling dan dua lapisan konvolusi untuk merekonstruksi data menjadi ukuran semula, yaitu 48 × 7. Representasi pada lapisan encoder kemudian dapat divisualisasikan melalui feature maps dan activation maps untuk mengamati respons filter terhadap perubahan data sepanjang waktu.



Gambar 3.5.2. Arsitektur Convolutional Autoencoder CNN 2D.

Gambar 3.5.2 menunjukkan arsitektur CNN 2D berbasis convolutional autoencoder yang digunakan untuk mengekstraksi representasi visual dari data time-series yang telah ditransformasikan menjadi citra Recurrence Plot. Model menerima masukan berupa citra berukuran 32 × 32 piksel dengan satu kanal. Bagian encoder terdiri atas dua lapisan konvolusi dua dimensi dengan delapan filter pada setiap lapisan, disertai fungsi aktivasi ReLU, MaxPooling, dan Adaptive Average Pooling. Proses ini menghasilkan representasi laten berukuran 8 × 4 × 4 yang merangkum karakteristik spasial dari citra masukan. Selanjutnya, decoder menggunakan interpolasi dan lapisan konvolusi untuk mengembalikan resolusi citra menjadi 32 × 32 piksel, dengan fungsi aktivasi Tanh pada lapisan keluaran. Representasi internal CNN 2D dapat divisualisasikan melalui feature maps untuk mengamati respons filter terhadap struktur kemiripan temporal yang terdapat pada citra Recurrence Plot.

3.6 Visualisasi Data dan Hasil Model

Visualisasi meliputi EDA terdahulu, citra kemiripan rekuren, input-rekonstruksi, kernel awal, aktivasi layer pertama dan kedua, respons aktivasi CNN 1D yang disejajarkan dengan temperatur, peta aktivasi CNN 2D, error rekonstruksi citra, training loss, dan proyeksi PCA embedding test. Semua grafik CNN ditempatkan pada output/cnn. Kernel 2D ditampilkan dalam bentuk koefisien terflatten; bentuk tersebut tidak langsung memetakan waktu.

3.7 Evaluasi Model

Evaluasi utama bersifat deskriptif-visual: apakah representasi memperlihatkan respons yang bervariasi, dapat dipetakan ke posisi waktu, dan dapat ditafsirkan tanpa mengubahnya menjadi klaim kausal. MSE reconstruction hanya pemeriksaan pendukung dan dihitung terpisah pada ruang numerik 1D dan citra 2D. PCA hanya proyeksi, bukan bukti cluster yang stabil. Uji multi-seed dan variasi window tidak menjadi syarat untuk tujuan deskriptif awal, tetapi membatasi generalisasi.

3.8 Perangkat dan Tools

Python, pandas, NumPy, scikit-learn, Matplotlib, PyTorch 2.10.0+cpu. Pengujian dilakukan pada runtime CPU lingkungan eksekusi, bukan GPU pengguna.

4. HASIL DAN PEMBAHASAN

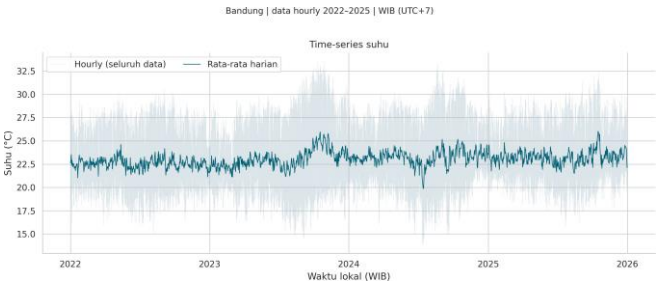
4.1 Gambaran Umum Dataset

35.064 pengamatan hourly selama empat tahun. Tidak ada missing values menurut audit awal. Pola hujan bersifat sparse: 73,25% observasi memiliki presipitasi nol menurut laporan repository.

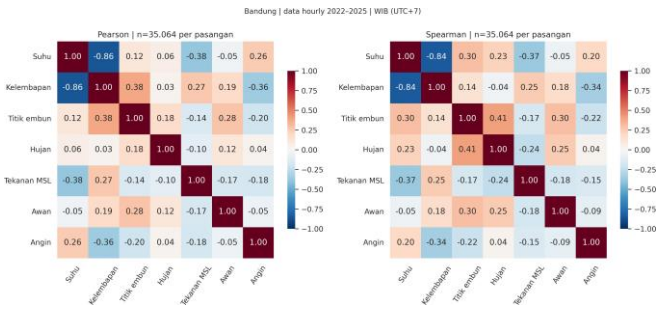
4.2 Hasil Preprocessing

Data train/validation/test dibagi secara kronologis. Sebanyak 365/183/182 window nonoverlap 48 jam digunakan; scaler dan parameter eksperimen disimpan untuk reproduksibilitas.

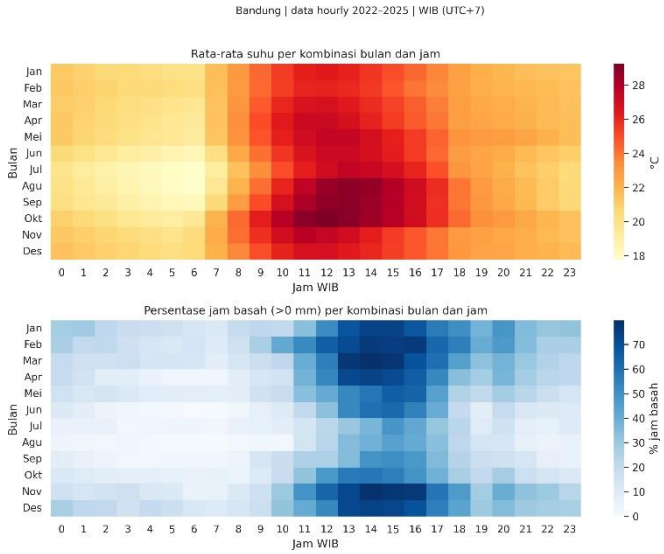
4.3 Hasil Visualisasi Time-Series



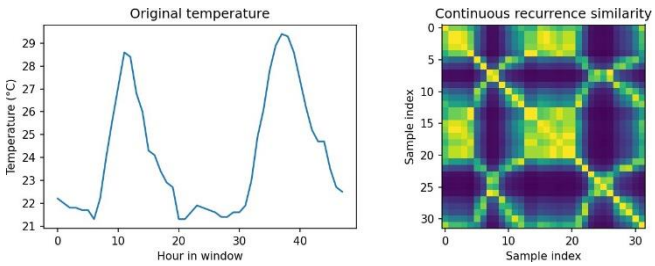
Gambar EDA 1. Temperatur sepanjang periode pengamatan.



Gambar EDA 2. Korelasi antarvariabel meteorologi.



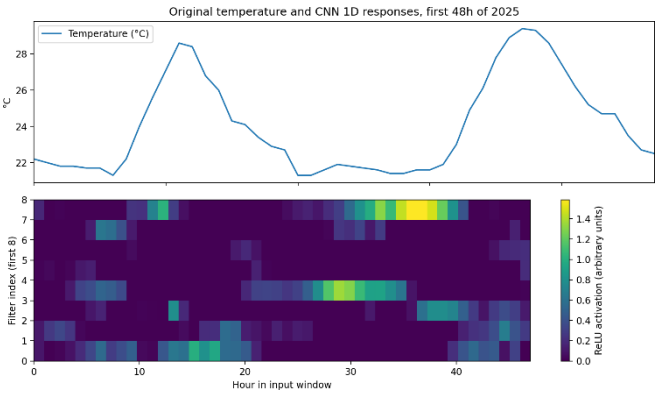
Gambar EDA 3. Variasi pola berdasarkan bulan dan jam.



Gambar 1. Deret temperatur dan matriks kemiripan rekuren pada window contoh; diagonal dan simetri berasal dari definisi transformasi.

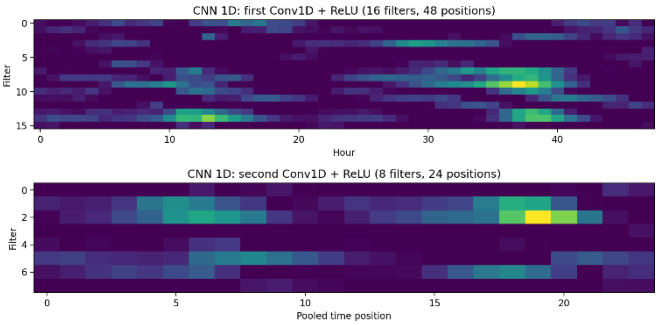
Lima belas grafik EDA dari repository dipertahankan sebagai konteks. Grafik recurrence_example.png menampilkan temperatur 48 jam dan matriks kemiripan 32×32. Nilai diagonal matriks selalu 1 karena setiap titik dibandingkan dengan dirinya sendiri; simetri matriks juga berasal dari rumus transformasi, bukan hasil pembelajaran CNN. Kesamaan warna pada pasangan indeks waktu menunjukkan kedekatan *temperatur ternormalisasi dalam window*, bukan kesamaan seluruh kondisi cuaca. Normalisasi per-window membuang tingkat temperatur absolut.

4.4 Hasil Penerapan dan Evaluasi CNN



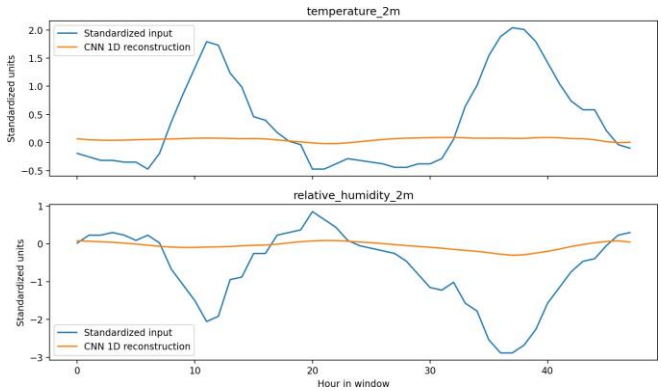
Gambar 2. Temperatur dan respons aktivasi CNN 1D yang disejajarkan menurut posisi waktu.

Analisis Gambar 2 — Respons kuat beberapa kanal tampak berdekatan dengan kenaikan temperatur pada sekitar jam 10–15 dan 35–42. Namun kesesuaian posisi tidak membuktikan filter mendeteksi kenaikan suhu: seluruh tujuh variabel masuk bersama-sama, bobot konvolusi mencampur kanal, dan ReLU menghapus respons negatif. Perlu analisis ablasi per variabel atau perturbasi input untuk menguji sensitivitas khusus terhadap temperatur.



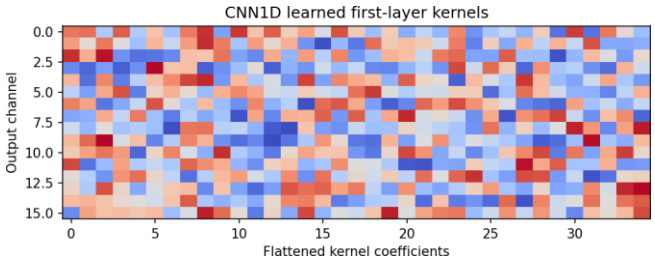
Gambar 3. Perbandingan aktivasi intermediate CNN 1D sebelum dan setelah pengurangan resolusi.

Analisis Gambar 3 — Lapisan pertama mempertahankan 48 posisi dan 16 kanal, sedangkan lapisan kedua menampilkan 24 posisi dan delapan kanal akibat max-pooling. Area aktivasi yang lebih lebar pada lapisan kedua dapat berasal dari agregasi dan receptive field yang membesar, bukan semata-mata pola meteorologi lebih kompleks. Intensitas warna antarpanel tidak layak dibandingkan sebagai besaran absolut tanpa skala warna bersama.



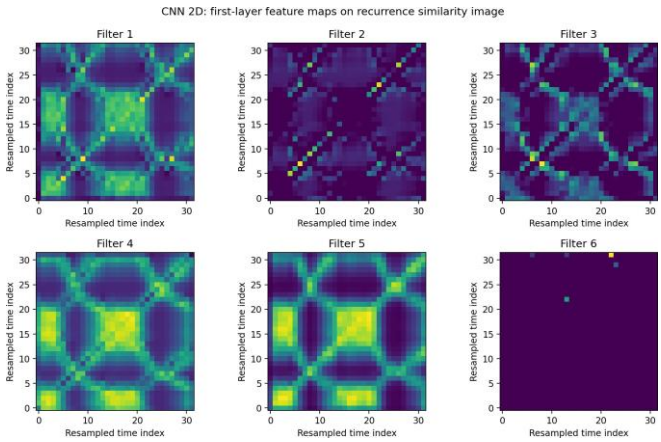
Gambar 4. Perbandingan input dan rekonstruksi variabel pada CNN 1D.

Analisis Gambar 4 — Garis rekonstruksi temperatur dan kelembapan relatif berada dekat nol pada skala terstandardisasi, sementara input menunjukkan variasi besar dan ekstrem lokal. Ini mengindikasikan kecenderungan prediksi menuju rerata dan underfitting pada checkpoint tiga epoch. MSE test 0,8924 tidak cukup untuk menyatakan representasi berhasil mempertahankan bentuk gelombang; perlu pembandingan terhadap baseline prediksi nol, MSE per fitur, dan korelasi temporal rekonstruksi.



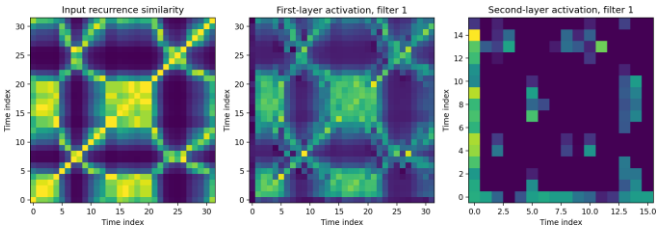
Gambar 5. Koefisien kernel konvolusi awal CNN 1D; tidak dapat langsung diberi makna fisik tunggal.

Analisis Gambar 5 — Setiap baris memuat koefisien filter keluaran pertama yang merangkum tujuh kanal input dan lima posisi temporal (35 koefisien). Tanda positif/negatif menunjukkan kontribusi linear sebelum ReLU, bukan arah hubungan kausal dengan cuaca. Flattening menyembunyikan batas antarkanal; penyajian ulang dalam tensor 7 × 5 per filter akan memudahkan pemeriksaan struktur bobot.



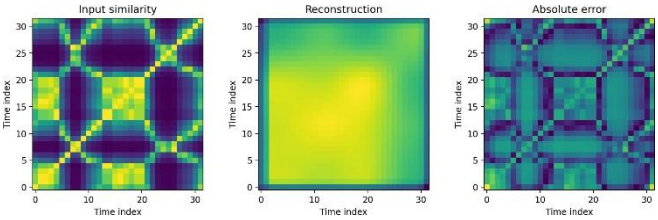
Gambar 6. Enam feature maps CNN 2D terhadap citra kemiripan.

Analisis Gambar 6 — Filter 1, 4, dan 5 tampak merespons area luas dan pola blok, sedangkan filter 2 lebih menonjolkan elemen diagonal; filter 6 hampir tidak aktif pada contoh ini. Perbedaan tersebut mendukung adanya selektivitas respons antarkanal, tetapi belum membuktikan fitur yang stabil lintas window. Diagonal terang sudah melekat pada definisi kemiripan S(i,i)=1 dan bukan pola yang ditemukan CNN.



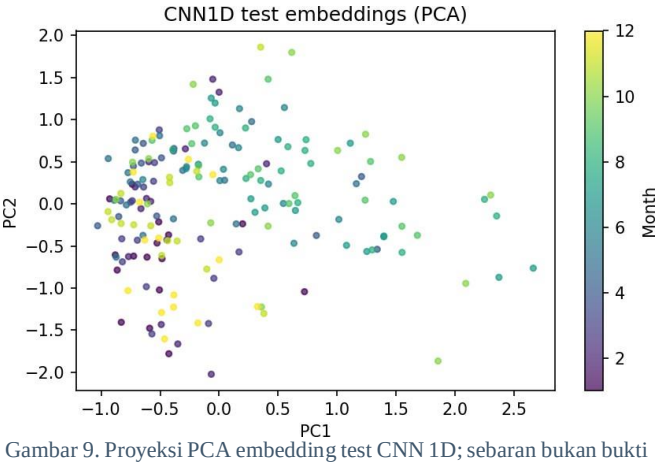
Gambar 7. Representasi intermediate CNN 2D pada dua tingkat layer.

Analisis Gambar 7 — Struktur geometris input sebagian masih terlihat pada aktivasi awal, tetapi representasi setelah pooling lebih kasar dan selektif. Penyusutan dari 32 × 32 ke 16 × 16 mengurangi ketelitian posisi pasangan waktu; tahap adaptive pooling selanjutnya menjadi 4 × 4. Interpretasi spasial di sini berarti hubungan dua indeks waktu, bukan lokasi geografis atau peta cuaca.



Gambar 8. Citra kemiripan input, rekonstruksi, dan galat absolut per piksel.

Analisis Gambar 8 — Rekonstruksi menjadi permukaan halus dan tidak mempertahankan garis diagonal serta batas blok yang tajam. Peta galat menonjol di lokasi struktur yang hilang, sehingga MSE test 0,09081 harus dibaca bersama kegagalan mempertahankan detail morfologi. Karena decoder berakhir dengan Tanh dan target berada dalam rentang 0–1, perlu juga memeriksa kecocokan rentang output dan kemungkinan bias akibat fungsi aktivasi.



Gambar 9. Proyeksi PCA embedding test CNN 1D; sebaran bukan bukti klaster yang tervalidasi.

Analisis Gambar 9 — Titik membentuk sebaran kontinu dengan beberapa titik ekstrem, bukan kelompok musim yang terpisah jelas. Warna bulan saling bertumpang tindih; tanpa explained variance ratio, validasi stabilitas, atau pengujian separabilitas, tidak tepat menyimpulkan encoder telah mengisolasi siklus musiman. PCA hanya merangkum variasi linear embedding.

Gambar 10. Proyeksi PCA embedding test CNN 2D; sumbu PCA bukan variabel meteorologi.

Analisis Gambar 10 — Embedding CNN 2D juga menunjukkan tumpang tindih warna bulan dan tidak menampilkan batas klaster yang tegas. Sumbu PC1 dan PC2 tidak setara dengan temperatur atau waktu; hasil dipengaruhi transformasi kemiripan yang menghilangkan level temperatur absolut. Perbedaan rentang sumbu terhadap PCA 1D tidak menunjukkan mutu representasi yang lebih tinggi.

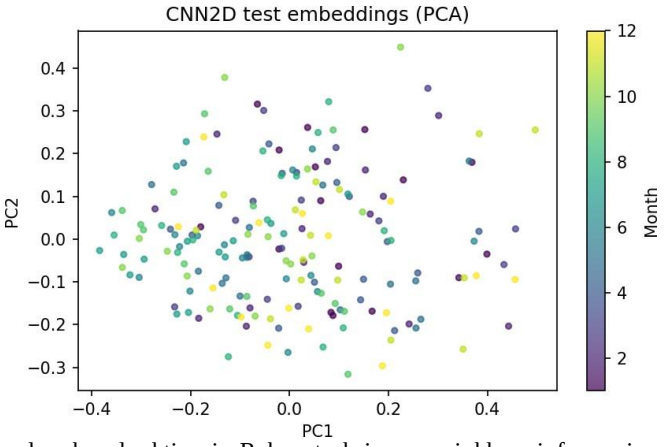
Eksperimen baseline tiga epoch menghasilkan MSE train/validation/test CNN 1D: 0,9179 / 1,0842 / 0,8924. CNN 2D: 0,09177 / 0,09128 / 0,09081. MSE 1D berasal dari tujuh variabel terstandardisasi, sedangkan MSE 2D dari matriks kemiripan temperatur; nilai-nilai tersebut **tidak** boleh digunakan untuk menentukan model yang lebih baik.

Seluruh gambar CNN adalah keluaran model checkpoint baseline yang tersimpan. Gambar 2–7 ditambahkan melalui src/stage7_visual_interpretation.py tanpa pelatihan ulang, memakai contoh window 48 jam pertama pada tahun 2025. Oleh sebab itu, pembacaan rinci grafik contoh tidak dapat digeneralisasi ke semua window.

4.5 Insight dan Interpretasi

Hasil visualisasi memperlihatkan **tiga cara membaca data yang berbeda**. Pertama, grafik time-series mempertahankan nilai fisik dan urutan waktu, sehingga perubahan temperatur dapat ditelusuri secara langsung. Kedua, CNN 1D menampilkan intensitas respons beberapa filter sepanjang waktu. Posisi aktivasi dapat disejajarkan dengan data asli, tetapi besarnya respons belum menunjukkan bahwa filter memiliki satu fungsi meteorologis tertentu. Ketiga, matriks kemiripan dan CNN 2D menampilkan hubungan antara *pasangan posisi waktu*. Bentuk garis atau blok pada matriks adalah pola kedekatan temperatur yang ditentukan oleh transformasi; feature maps memperlihatkan bagaimana layer CNN merespons struktur visual itu, bukan bukti pola baru.

Visualisasi dua layer memperlihatkan perbedaan resolusi



dan kanal aktivasi. Rekonstruksi menunjukkan informasi yang dipertahankan dan yang tidak terpulihkan secara sempurna pada baseline. PCA memberi gambaran ringkas penyebaran embedding, namun tidak memberikan makna fisik langsung bagi sumbu PC1/PC2. **Kontribusi yang dapat didukung hasil aktual adalah perbedaan sudut pandang visual dan keterbatasan interpretasinya, bukan penemuan meteorologi baru atau keunggulan arsitektur.**

4.6 Diskusi

Eksperimen menghasilkan visualisasi yang dapat dibaca pada tiga tingkat: data asli, transformasi kemiripan, dan respons model. CNN 1D lebih langsung disejajarkan dengan urutan waktu; CNN 2D menekankan hubungan antarpasangan waktu, namun hanya memakai temperatur dan menghilangkan amplitudo absolut akibat normalisasi. Perbandingan bersifat deskriptif, bukan kompetisi skor. Belum ada evaluasi kestabilan lintas seed atau variasi window; EDA historis juga telah melihat periode test. Hal tersebut membatasi generalisasi, tetapi tidak membatalkan tujuan mendeskripsikan keluaran visual model.

5. KESIMPULAN DAN SARAN

5.1 Kesimpulan

Convolutional autoencoder 1D dan 2D menghasilkan visualisasi yang saling melengkapi: CNN 1D memetakan respons filter terhadap posisi waktu, sedangkan pendekatan 2D menampilkan struktur kemiripan temperatur antarwaktu dan respons filter pada citra tersebut. Grafik rekonstruksi, aktivasi antar-layer, dan PCA menambah sudut pandang terhadap representasi, dengan keterbatasan interpretasi masing-masing. Tujuan penelitian tercapai pada tingkat demonstrasi dan pembacaan visual baseline; penelitian ini tidak bertujuan menemukan pola meteorologi baru.

5.2 Saran

Perluas contoh visualisasi pada beberapa musim dan kondisi cuaca; tambahkan interaksi untuk memilih window dan filter; pertimbangkan RP biner/GAF dan citra multivariat jika diperlukan. Pelatihan lebih lama, variasi seed/window, dan evaluasi kuantitatif tambahan bersifat pengembangan opsional, bukan prasyarat untuk menjelaskan hasil visualisasi saat ini.

DAFTAR PUSTAKA

[1] J.-P. Eckmann, S. O. Kamphorst, and D. Ruelle, "Recurrence Plots of Dynamical Systems," Europhysics Letters, vol. 4, no. 9, pp. 973–977, 1987. DOI: 10.1209/0295-5075/4/9/004.

[2] Z. Wang and T. Oates, "Imaging Time-Series to Improve Classification and Imputation," Proceedings of the 24th International Joint Conference on Artificial Intelligence (IJCAI), 2015, pp. 3939–3945.

[3] H. I. Fawaz et al., "Deep learning for time series classification: a review," Data Mining and Knowledge Discovery, vol. 33, pp. 917–963, 2019. DOI: 10.1007/s10618-019-00619-1.

[4] Open-Meteo, "Historical Weather API," https://open-meteo.com/en/docs/historical-weather-api (accessed November 2026).

LAMPIRAN DAN PETA REPRODUKSIBILITAS

Repository proyek memuat README bagian "CNN representation-learning experiment (new)", laporan reports/07_cnn_paper.md dan reports/06_cnn_readiness.md, kode tahap 6–7, checkpoint, serta visualisasi. Hyperlink di dokumen menunjuk ke path masing-masing berkas pada branch main GitHub. Isi dan nama path diselaraskan dengan inventaris ZIP pendamping.

LAMPIRAN A. PARAMETER EKSPERIMEN

Parameter	Konfigurasi
Dataset	Bandung 2022-2025; hourly
Pembagian data	Train 2022-2023; validation 2024; test 2025
Window	48 jam, tanpa overlap
CNN 1D	7 variabel meteorologi numerik
CNN 2D	Kemiripan temperatur 32 x 32
Optimizer	Adam, learning rate 0.001
Batch / epich / seed	64 /3/42
Evaluasi	Reconstruction MSE (masing-masing ruang)

LAMPIRAN B. REPOSITORY, STATUS SUMBER, DAN NAVIGASI

Repository GitHub: bandung-weather-timeseries-cnn — README (main)

Seluruh path pada laporan relatif terhadap akar repository. Contoh: src/stage6_cnn_experiments.py berarti berkas stage6_cnn_experiments.py di dalam folder src. Klik hyperlink biru untuk membuka berkas atau direktori pada branch main GitHub. Nama dan struktur path telah dicocokkan dengan ZIP proyek; GitHub dapat menampilkan versi terbaru setelah merge.

5.3 Dokumentasi dan paper

README.md
reports/06_cnn_readiness.md
reports/07_cnn_paper.md
reports/07_cnn_paper.pdf

5.4 Implementasi

src/common.py
src/run_all.py
src/stage1_validation.py
src/stage2_eda.py
src/stage3_preprocessing.py
src/stage4_visualization.py
src/stage5_patterns.py
src/stage6_cnn_experiments.py
src/stage7_visual_interpretation.py
src/verify_results.py

5.5 Data dan konfigurasi

data/raw/BandungRawWeather.csv
data/processed/bandung_weather_hourly_clean.csv
requirements.txt
output/cnn/results.json
output/cnn/scaler.json
output/cnn/visual_interpretation_manifest.json

5.6 Artefak dan checkpoint

output/cnn/cnn1d.pt
output/cnn/cnn2d.pt
output/cnn/cnn1d_training.csv
output/cnn/cnn2d_training.csv

LAMPIRAN C. INDEKS GAMBAR DAN HASIL

Gambar 1 — output/cnn/recurrence_example.png
Gambar 2 — output/cnn/cnn1d_temporal_response.png
Gambar 3 — output/cnn/cnn1d_intermediate_layers.png
Gambar 4 — output/cnn/cnn1d_reconstruction_lines.png
Gambar 5 — output/cnn/cnn1d_kernels.png
Gambar 6 — output/cnn/cnn2d_feature_map_grid.png
Gambar 7 — output/cnn/cnn2d_intermediate_layers.png
Gambar 8 — output/cnn/cnn2d_reconstruction_error.png
Gambar 9 — output/cnn/cnn1d_pca.png
Gambar 10 — output/cnn/cnn2d_pca.png

LAMPIRAN D. INVENTARIS REPOSITORY ZIP

Inventaris berkas proyek yang relevan berdasarkan ZIP pendamping (mengabaikan .git, .venv, dan cache Python). Setiap path yang ditampilkan sebagai hyperlink diarahkan ke lokasi file atau folder pada GitHub branch main. Inventaris ini merupakan indeks navigasi dan tidak menggantikan pemeriksaan versi commit untuk reproduksibilitas yang ketat.

5.7 reports/ (8 berkas)

reports/01_data_validation.md
reports/02_eda.md
reports/03_preprocessing.md
reports/04_visualization_guide.md
reports/05_pattern_analysis_insight.md
reports/06_cnn_readiness.md
reports/07_cnn_paper.md
reports/07_cnn_paper.pdf

5.8 output/figures/ (16 berkas)

output/figures/01_temperature_timeseries.png
output/figures/02_humidity_timeseries.png
output/figures/03_precipitation_analysis.png
output/figures/04_precipitation_distribution.png
output/figures/05_monthly_temperature_pattern.png
output/figures/06_hourly_temperature_humidity.png
output/figures/07_temperature_vs_humidity.png
output/figures/08_cloud_cover_vs_precipitation.png
output/figures/09_humidity_vs_precipitation.png
output/figures/10_correlation_heatmaps.png
output/figures/11_variable_distributions.png
output/figures/12_month_hour_patterns.png
output/figures/13_monthly_hourly_rain_patterns.png
output/figures/14_autocorrelation.png
output/figures/15_temperature_anomaly_candidates.png
output/figures/figure_manifest.json

5.9 output/cnn/ (28 berkas)

output/cnn/cnn1d.pt
output/cnn/cnn1d_activations.png
output/cnn/cnn1d_intermediate_layers.png
output/cnn/cnn1d_kernels.png
output/cnn/cnn1d_loss.png
output/cnn/cnn1d_pca.png
output/cnn/cnn1d_reconstruction.png
output/cnn/cnn1d_reconstruction_lines.png
output/cnn/cnn1d_temporal_response.png
output/cnn/cnn1d_test_embedding.npy
output/cnn/cnn1d_test_pca.npy
output/cnn/cnn1d_training.csv
output/cnn/cnn2d.pt
output/cnn/cnn2d_activations.png
output/cnn/cnn2d_feature_map_grid.png
output/cnn/cnn2d_intermediate_layers.png
output/cnn/cnn2d_kernels.png
output/cnn/cnn2d_loss.png
output/cnn/cnn2d_pca.png
output/cnn/cnn2d_reconstruction.png
output/cnn/cnn2d_reconstruction_error.png
output/cnn/cnn2d_test_embedding.npy
output/cnn/cnn2d_test_pca.npy
output/cnn/cnn2d_training.csv
output/cnn/recurrence_example.png
output/cnn/results.json
output/cnn/scaler.json
output/cnn/visual_interpretation_manifest.json

5.10 output/tables/ (43 berkas)

output/tables/annual_changes.csv
output/tables/annual_summary.csv
output/tables/anomaly_candidates_by_year.csv
output/tables/autocorrelation.csv
output/tables/cnn_recommended_split_plan.csv
output/tables/conditional_rain_cloud.csv
output/tables/conditional_rain_humidity.csv
output/tables/constant_runs.csv
output/tables/correlation_month_hour_residual_pearson.csv
output/tables/correlation_pearson.csv
output/tables/correlation_spearman.csv
output/tables/daily_summary.csv
output/tables/data_dictionary_processed.csv
output/tables/data_dictionary_raw.csv
output/tables/descriptive_statistics.csv
output/tables/dry_wet_comparison.csv
output/tables/eda_summary.json
output/tables/environment.json
output/tables/extra_timestamps.csv
output/tables/hourly_pattern.csv
output/tables/iqr_diagnostics.csv
output/tables/key_associations.csv
output/tables/missing_timestamps.csv
output/tables/missing_values.csv
output/tables/month_hour_temperature.csv
output/tables/month_hour_wet_pct.csv
output/tables/monthly_coverage.csv
output/tables/monthly_pattern.csv
output/tables/monthly_summary.csv
output/tables/pattern_evidence.json
output/tables/preprocessing_audit.csv
output/tables/quality_checks.csv
output/tables/quality_flagged_rows.csv
output/tables/rain_threshold_sensitivity.csv
output/tables/source_metadata.json
output/tables/temperature_anomaly_candidates.csv

output/tables/temperature_anomaly_scores.csv
output/tables/top_rain_days.csv
output/tables/top_rain_hours.csv
output/tables/top_temperature_anomalies.csv
output/tables/validation_checks.csv
output/tables/verification_results.json
output/tables/weather_code_frequency.csv

5.11 output/manifests/ (5 berkas)

output/manifests/stage1.json
output/manifests/stage2.json
output/manifests/stage3.json
output/manifests/stage4.json
output/manifests/stage5.json